

PROBABILITÀ E STATISTICA PER L'INFORMATICA

1. STATISTICA DESCRITTIVA

1.1 DESCRIVERE I DATI

1.2 RIASSUMERE I DATI

[Ross, capitoli 2 e 3]

INTRODUZIONE

STATISTICA: arte di "imparare dai dati"

STATISTICA DESCRITTIVA

Descrivere e riassumere
i dati

"APERITIVO DEL CORSO"

.....>

STATISTICA INFERENZIALE

Trarre conclusioni
dai dati

II PARTE DEL CORSO

Qualche esempio.

1) Lancio una moneta 10 volte, ottengo TESTA 7 volte.

Posso concludere che la moneta è truccata?

NO!

(Con 70 teste in 100 lanci?)

Quasi certamente SÌ! → Vedremo perché)

2) In occasione di un'elezione con due candidati (ballottaggio), vengono intervistati 1000 elettori, di questi 550 dichiarano di votare A, i restanti 450 dichiarano di votare B.

Chi vincerà le elezioni?

Quasi certamente A!

Vedremo perché

(Se gli intervistati sono scelti casualmente, e se sono sinceri!)

3) Si sviluppa un vaccino per ridurre le forme gravi di una malattia.

Il vaccino viene somministrato a un gruppo di N pazienti e, di questi, M sviluppano forme gravi della malattia.

Simultaneamente viene somministrata una sostanza innocua (placebo) a un altro gruppo di N pazienti (gruppo di controllo) di questi, M' sviluppano forme gravi della malattia.

I dati mostrano che $M < M'$ (meno malattie gravi nel gruppo col vaccino rispetto al gruppo col placebo).

Possiamo concludere che il vaccino è davvero efficace?

Dipende!

Da quanto M è minore di M' ,
ma anche da quanto N è grande

($N=3, M=0, M'=1 \leadsto$ dati non conclusivi)

- Per trarre conclusioni dai dati, occorre tenere conto del ruolo che gioca il caso. Questo è chiaro per l'Esempio 1. Per gli Esempi 2 e 3, il caso entra nella scelta di un campione = sottoinsieme di individui della "popolazione".

Descrivere matematicamente
i fenomeni casuali

PROBABILITÀ

I PARTE

DEL CORSO

1. DESCRIVERE I DATI

Misuriamo una certa **variabile** (qualitativa o quantitativa) in un campione, ottenendo un **insieme di dati**:

$x_1, x_2, x_3, \dots, x_N$ con $N = \text{numero di dati}$

Se l'insieme contiene un **numero ridotto di valori distinti**, i dati possono essere riassunti in una **tabella delle frequenze**

Esempio. Marta intervista i suoi $N=20$ compagni di classe e chiede la squadra di calcio preferita, ottenendo le risposte:

JUV, MIL, JUV, ATA, NES, NES, ATA, MIL, INT, NES, ATA, ATA, NES, JUV, NES, INT, NES, JUV, NES, ATA

VALORI	FREQ. ASS. f_i	FREQUENZE RELATIVE $p_i = f_i/N$
JUV	4	$4/20 = 0,2 = 20\%$
MIL	2	$2/20 = 0,1 = 10\%$
ATA	5	$5/20 = 0,25 = 25\%$
INT	2	$2/20 = 0,1 = 10\%$
NES	7	$7/20 = 0,35 = 35\%$

- Frequenza assoluta** $f_i :=$ numero di volte in cui compare "i" nell'insieme di dati

- **Frequenza relativa** $p_i := \frac{f_i}{N} =$ frazione di volte in cui compare "i" nell'insieme di dati

Esempio (Ross) - Vengano rilevati i giorni di assenza per malattia di $N = 50$ lavoratori di una azienda negli ultimi due mesi:

2, 2, 0, 0, 5, 8, 3, 4, 1, 0, 0, 7, 1, 7, 1, 5,
 4, 0, 4, 0, 1, 8, 9, 7, 0, 1, 7, 2, 5, 5, 4, 3,
 3, 0, 0, 2, 5, 1, 3, 0, 1, 0, 2, 4, 5, 0, 5, 7, 5, 1

VALORI	FREQ. ASS. f_i	FREQ. REL. $p_i = f_i/N$
0	12	$12/50 = 0,24 = 24\%$
1	8	$8/50 = 0,16 = 16\%$
2	5	$5/50 = 0,1 = 10\%$
3	4	$4/50 = 0,08 = 8\%$
4	5	$5/50 = 0,1 = 10\%$
5	8	$8/50 = 0,16 = 16\%$
6	0	$0/50 = 0 = 0\%$
7	5	$5/50 = 0,1 = 10\%$
8	2	$2/50 = 0,04 = 4\%$
9	1	$1/50 = 0,02 = 2\%$


Nel primo esempio i dati sono **qualitativi** (o categorici)

nel secondo esempio i dati sono **quantitativi** (o numerici) -

D'ora in avanti considereremo insiemi di **dati quantitativi**.

È utile rappresentare le frequenze (ass. o rel.) mediante un grafico a barre, detto **istogramma** (oppure a bastoncini).

Esempio (Ross). Grafico ricavato dalla tabella delle frequenze:



Osservazione. Il grafico (istogramma) è una rappresentazione **equivalente** della tabella delle frequenze, infatti a partire dal grafico si può ricavare la tabella.

Può capitare di avere insiemi di dati che assumono un **numero elevato di valori distinti**. In tal caso, conviene suddividere i valori assunti in intervalli, detti **classi**, quindi possiamo determinare le frequenze di ciascuna classe.

Esempio (Ross) Vengano misurati i livelli di **colesterolo totale** nel sangue (mg/dl) di un insieme di $N=40$ individui:

213, 174, 193, 196, 220, 183, 194, 200, 192, 200,
200, 199, 178, 183, 188, 193, 187, 181, 193, 205,
196, 211, 202, 213, 216, 206, 195, 191, 171, 194,
184, 191, 221, 212, 221, 204, 204, 191, 183, 227

Molti valori sono distinti e hanno dunque frequenza 1. Le frequenze dei singoli valori assunti sono poco significative.


Data che $\min(\text{dati}) = 171$, $\max(\text{dati}) = 227$, scegliamo le classi

$[170, 180)$ $[180, 190)$ $[190, 200)$ $[200, 210)$ $[210, 220)$ $[220, 230)$

CLASSI	FREQ. ASS. f_i	FREQ. REL. $p_i = f_i/N$
$[170, 180)$	3	$3/40 = 0,075 = 7,5\%$
$[180, 190)$	7	$7/40 = 0,175 = 17,5\%$
$[190, 200)$	13	$13/40 = 0,325 = 32,5\%$
$[200, 210)$	8	$8/40 = 0,2 = 20\%$
$[210, 220)$	5	$5/40 = 0,125 = 12,5\%$
$[220, 230)$	4	$4/40 = 0,10 = 10\%$

Disegniamo ora l'istogramma delle frequenze.

FREQUENZE



Osservazione. Raggruppando in classi perdiamo informazione.

Ad esempio, dalla tabella (o, equivalentemente, dal grafico) sappiamo che ci sono 3 dati nella prima classe 170-180, ma non sappiamo con precisione i loro valori. Tuttavia, il raggruppamento in classi permette di calcolare le frequenze e queste danno un'idea migliore della distribuzione dei dati.

DATI A COPPIE (BIVARIATI)

Gli insiemi di dati presentati finora si riferivano a una singola variabile (o caratteristica) misurata sugli individui del campione. Talvolta è interessante misurare per ciascun individuo due variabili (o anche più di due).

Abbiamo in questa caso un insieme di N dati a coppie, detti anche dati bivariati:

$$(x_1, y_1), (x_2, y_2), (x_3, y_3), \dots, (x_N, y_N)$$

Per ciascun "individuo" $i = 1, \dots, N$ indichiamo con x_i la prima variabile misurata e con y_i la seconda.

Esempio (Ross) Rileviamo il numero di anni di scuola (prima variabile) e le pulsazioni a riposo (seconda variabile) in un campione di $N = 10$ individui. I dati (x_i, y_i) sono

(12, 73) (16, 67) (13, 74) (18, 63) (19, 73)
(12, 84) (18, 60) (19, 62) (12, 76) (14, 71)

Potremmo focalizzarci solo su una delle due variabili, ad es. la prima, calcolare le frequenze e rappresentarne il grafico mediante un istogramma, come sopra.


Vogliamo invece evidenziare se c'è una possibile associazione, o correlazione, tra le due variabili rilevate.

Al crescere degli anni di scuola aumentano le pulsazioni? Oppure diminuiscono?

In assoluta, né l'una né l'altra: (16, 67)  (19, 73)
(19, 62)

Tuttavia si può forse evidenziare una tendenza?

Per scoprirlo, disegniamo il **diagramma di dispersione**, che rappresenta i punti (x_i, y_i) nel piano cartesiano.



Questo grafico evidenzia come all'aumentare di una variabile (anni di scuola) l'altra variabile (pulsazioni) ha la "tendenza" a diminuire. Si parla di **correlazione negativa**.

In generale, è possibile osservare una correlaz. positiva, o nessuna correlazione significativa.

Presto **renderemo precise** (quantitative) queste considerazioni.

Osservazione Correlazione **non significa causalità**!

Non è detto che l'aumento di una variabile causi la diminuzione dell'altra. Potrebbe esserci ad esempio una "**causa comune**": nel caso specifico, ad es., l'età.

Concludiamo osservando che per un insieme di dati a coppie

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$


è possibile calcolare le **frequenze congiunte**.

Per ogni valore distinto (x, y) si calcola:

- **frequenza assoluta** $f_{(x,y)} := \begin{cases} \text{num. di volte in cui } (x,y) \\ \text{compare nell'insieme di dati} \end{cases}$
- **frequenza relativa** $p_{(x,y)} := \frac{f_{(x,y)}}{N} = \begin{cases} \text{fraz. di volte in cui} \\ (x,y) \text{ compare} \\ \text{nell'insieme di dati.} \end{cases}$

Se i valori distinti (x, y) sono tanti, è opportuno fare una suddivisione in classi per x e/o y .

Esempio (Ross) Riprendiamo i dati su anni di scuola / pulsazioni



Osserviamo che i dati (x_i, y_i) sono tutti distinti (come coppie)

È opportuno raggruppare i dati in classi. In questo esempio i dati sono troppo pochi ($N=10$) ed è inevitabile avere frequenze basse, ma facciamo comunque l'esercizio.

- Classi per x :
 $\begin{array}{ccc} \{12, 13, 14\} & \{15, 16, 17\} & \{18, 19\} \\ \text{"} & \text{"} & \text{"} \\ [12, 15) & [15, 18) & [18, 21) \end{array}$
- Classi per y : $[55, 65)$ $[65, 75)$ $[75, 85)$

Frequenze congiunte assolute:

(x, y)	$[55, 65)$	$[65, 75)$	$[75, 85)$
$[12, 14]$	0	3	2
$[15, 17]$	0	1	0
$[18, 20]$	3	1	0

Ritorniamo sulle frequenze congiunte alla fine del corso.

2. RIASSUMERE I DATI

Consideriamo un insieme di N dati reali

$$x_1, x_2, \dots, x_N$$

Abbiamo imparato a descrivere i dati mediante le frequenze e a rappresentarli in un grafico (istogramma) -

Vogliamo ora riassumere l'insieme di dati mediante quantità numeriche, dette statistiche campionarie.

IDEA: sintetizzare le proprietà salienti dei dati -

INDICI DI POSIZIONE

Per descrivere il "centro" dell'insieme di dati, definiamo la

MEDIA CAMPIONARIA $\bar{x} := \frac{x_1 + x_2 + \dots + x_N}{N} = \frac{1}{N} \sum_{i=1}^N x_i$

Esempio. Insieme di dati: 1, 0, 7, 4, 4 ($N=5$)

Media campionaria $\bar{x} = \frac{1+0+7+4+4}{5} = \frac{16}{5} = 3,2$.

Esempio. Consideriamo la tabella delle Frequenze

VALORI	FREQUENZE
4	2
5	3
8	1

$N = 6$

Insieme di dati:

4, 4, 5, 5, 5, 8

Media campionaria

$$\bar{x} = \frac{4 \cdot 2 + 5 \cdot 3 + 8 \cdot 1}{\underbrace{4 + 4 + 5 + 5 + 5 + 8}_{2+3+1}} = \frac{31}{6}$$

In generale, data la tabella di frequenze

VALORI	FREQUENZE
z_1	f_1
z_2	f_2
$\vdots$	$\vdots$
z_M	f_M

La media campionaria è data da

$$\bar{x} = \frac{z_1 \cdot f_1 + z_2 \cdot f_2 + \dots + z_M \cdot f_M}{N}$$

con $N = f_1 + f_2 + \dots + f_M$.

Osservazione Trasformazioni lineari-affini dei dati

$$(y_i := a x_i + b)_{i=1, \dots, N} \quad a, b \in \mathbb{R}$$

Linearità della media:

$$\bar{y} = a \bar{x} + b$$

$$\frac{y_1 + \dots + y_N}{N} = a \frac{x_1 + \dots + x_N}{N} + b$$

Un'altra misura del "centro" dell'insieme dei dati, alternativa alla media, è la **MEDIANA CAMPIONARIA**

Per calcolarla, bisogna ordinare i dati $x_1, x_2, \dots, x_N$:

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(N)} \quad (\text{ordine crescente})$$

Intuitivamente: la **mediana** è il **valore in posizione centrale**.

► N dispari: la mediana è il dato di posto $\frac{N+1}{2}$

$\Downarrow$
 $\frac{N}{2}$ non è intero

$$m := x_{(\frac{N+1}{2})}$$

$\parallel$
intero successivo a $\frac{N}{2}$

► N pari: la mediana è la media aritmetica tra il dato di posto $\frac{N}{2}$ e quello di posto $\frac{N}{2} + 1$:

$\Downarrow$
 $\frac{N}{2}$ è intero

$$m := \frac{x_{(\frac{N}{2})} + x_{(\frac{N}{2} + 1)}}{2}$$

Esempio Consideriamo l'insieme di dati 1, 0, 7, 4, 4 ($N=5$ è dispari). Riordiniamo i dati:

$$0, 1, 4, 4, 7 \quad \Rightarrow \quad m = 4$$

Se i dati fossero stati 1, 0, 7, 4, 4, -5, allora

$$-5, 0, 1, 4, 4, 7 \quad \Rightarrow \quad m = \frac{1+4}{2} = 2,5$$

Esempio: Nel 2016 in Italia il reddito medio è stato

$$\bar{x} = 20.690 \text{ €}$$

Nello stesso anno, il reddito mediano è stato

$$m = 16.557 \text{ €}$$

(Osserviamo che media e mediana non coincidono: $\bar{x} \neq m$.)

► $\bar{x} = \frac{x_1 + x_2 + \dots + x_N}{N}$ è la media aritmetica dei redditi

► Metà degli Italiani ha un reddito minore o uguale a m ,
l'altra metà ha un reddito maggiore o uguale a m .

Da un anno all'altra, può accadere che il reddito medio aumenti mentre il reddito mediano diminuisca (oppure viceversa) - Come è possibile?

► La mediana è insensibile alle "code" $\begin{cases} -1, 0, 1 & \bar{x}=0, m=0 \\ -1, 0, 100 & \bar{x}=33, m=0 \end{cases}$

Generalizziamo la mediana: **QUARTILI CAMPIONARI**

$x_{(1)} \ x_{(2)} \ \dots \ x_{(i)} \ \dots \ x_{(j)} \ \dots \ x_{(k)} \ \dots \ x_{(N)}$ DATI ORDINATI

$\swarrow$ $\downarrow$ $\searrow$

$\sim 1/4$ DEI DATI $\sim$ METÀ DEI DATI $\sim 3/4$ DEI DATI

PRIMO QUARTILE q_1 MEDIANA m TERZO QUARTILE q_3

= SECONDO QUARTILE q_2

Più in generale, dato un numero $k \in [0, 100]$, definiamo il

k -esimo PERCENTILE CAMPIONARIO : valore t per cui

- ▶ (almeno) il $k\%$ dei dati $\leq t$;
- ▶ (almeno) il $(100-k)\%$ dei dati $\geq t$.

Ritroviamo i quartili: $k = 25, 50, 75$

$$p = \frac{k}{100} \in [0, 1] \quad p = 0,25 = \frac{1}{4} \quad 0,50 = \frac{1}{2} \quad 0,75 = \frac{3}{4}$$

$p = \frac{1}{4}$: $k = 25$ -esimo percentile = primo quartile q_1

$p = \frac{1}{2}$: $k = 50$ -esimo percentile = secondo quartile q_2
= mediana

$p = \frac{3}{4}$: $k = 75$ -esimo percentile = terzo quartile q_3

Come si calcola il k -esimo percentile t ? Scriviamo $\begin{cases} p = \frac{k}{100} \\ k = 100p \end{cases}$

1) Ordiniamo l'insieme di dati: $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(N)}$.

2) Se Np non è intero, $t = x_{(i)}$ è il dato la cui posizione i è l'intero successivo a Np .

3) Se Np è intero, $t = \frac{x_{(Np)} + x_{(Np+1)}}{2}$ è la media aritmetica del dato in posizione Np e del dato successivo.

Esempio. Consideriamo l'insieme di $N=10$ dati (già riordinati)

-6, -3, -3, 0, 0, 1, 10, 10, 10, 17

$p = \frac{1}{2}$: ($N \cdot \frac{1}{2} = 5$) MEDIANA (II QUANTILE q_2) $m = \frac{0+1}{2} = 0,5$ = 50° PERCENTILE

$p = \frac{1}{4}$: ($N \cdot \frac{1}{4} = 2,5$) I QUANTILE $q_1 = -3$ = 25° PERCENTILE

$p = \frac{3}{4}$: ($N \cdot \frac{3}{4} = 7,5$) III QUANTILE $q_3 = 10$ = 75° PERCENTILE

Attenzione! Esistono definizioni alternative di percentile nel caso 3) in cui Np è intero.

Ad es. il software R ne adotta di default una diversa.

Per usare la definizione che abbiamo dato noi, si scrive

> quantile(..., type = 2) [?quantile]